



INFORME DE LA PRÁCTICA CALIFICADA 2
CURSO FUNDAMENTOS DE DATA SCIENCE
Carrera de Ciencias de la Computación

Sección:4870

Alumnos:	
Código	Nombres y apellidos
u20242007	Cielo Anahí Mitma Ayala
u202321351	Iyari Maryuri Karin Alejandro Zelada
u202419766	Nicole Abigail Sánchez Martínez

2026-20

Índice

1. Introducción.....	3
2. Descripción del Problema: Caso del negocio.....	3
2.1. Descripción del caso y del dataset.....	3
2.2. Preguntas de negocio y preguntas analíticas.....	4
3. Inspección y comprensión del dataset.....	5
3.1. Diccionario de variables.....	5
3.2. Estructura inicial (filas, columnas, muestra, tipos de datos).....	8
4. Calidad, análisis exploratorio y visualizaciones.....	10
4.1. Completitud.....	10
4.2. Unicidad.....	13
Conversión de variables a factor.....	15
Corrección de la variable de fecha (arrival_date).....	15
Creación de nuevas variables.....	16
4.3. Consistencia.....	16
4.4. Validez.....	17
4.5. Exactitud.....	17
4.6. Análisis univariado.....	18
Resultados del análisis univariado — Variables numéricas.....	19
Resultados del análisis univariado — Variables categóricas.....	20
4.7. Valores atípicos.....	23
Resultados por variable.....	23
Decisiones tomadas.....	24
4.8. Análisis bivariado y multivariado.....	25
Resultado 1 — Cancelación por tipo de hotel.....	27
Resultado 2 — ADR promedio por tipo de hotel.....	27
Resultado 3 — Cancelación por segmento de mercado.....	27
Resultado 4 — Matriz de correlaciones.....	28
Decisiones tomadas a partir del análisis bivariado.....	29
4.9. Análisis temporal.....	31
5. Respuesta a las preguntas analíticas.....	34
6.1. Síntesis de hallazgos.....	37
7. Conclusiones y recomendaciones.....	38
7.1. Conclusiones.....	38
7.2. Recomendaciones.....	38
7.3. Limitación del análisis.....	38

CONTENIDO

1. Introducción

El presente informe tiene como finalidad analizar el conjunto de datos relacionado con las reservas hoteleras, aplicando técnicas de análisis exploratorio de datos mediante el software R y RStudio. A través de la inspección, comprensión y evaluación de la calidad de los datos, se busca obtener información relevante que permita responder las preguntas de negocio asignadas al grupo.

Asimismo, se emplearán medidas descriptivas, tablas y visualizaciones para identificar patrones, tendencias y relaciones entre las variables del dataset. Los hallazgos obtenidos servirán como base para formular conclusiones y recomendaciones que contribuyan a una mejor comprensión del comportamiento de las reservas hoteleras

2. Descripción del Problema: Caso del negocio

2.1. Descripción del caso y del dataset

El conjunto de datos "Hotel Booking Demand" registra información detallada sobre las reservas realizadas en dos tipos de alojamiento: un hotel urbano (City Hotel) y un hotel tipo resort (Resort Hotel). El dataset contiene diversas variables transaccionales y de perfil, incluyendo fechas de llegada, anticipación de la reserva (lead time), duración de la estancia, cantidad de huéspedes, segmento de mercado, requerimientos de estacionamiento, tarifa diaria promedio (ADR) y si la reserva fue cancelada o efectuada.

Usuarios potenciales y utilidad del análisis

Los resultados derivados de este conjunto de datos son de alto valor estratégico para distintas áreas del hotel:

- **Revenue Management:** Utilizarán el análisis para optimizar las estrategias de precios dinámicos, evaluando cómo fluctúa la tarifa diaria promedio según la anticipación de compra y el tipo de alojamiento.
- **Marketing:** Les permitirá identificar qué segmentos de mercado y canales de distribución generan la mayor cantidad de reservas efectivas, así como aquellos con las tasas de cancelación más altas, para ajustar el presupuesto de campañas.
- **Gerencia de Operaciones:** Podrán prever la carga de demanda física en las instalaciones, dimensionando adecuadamente el personal de limpieza, recepción y requerimientos de estacionamiento según la temporalidad y volumen de huéspedes.
- **Reservas y Atención al Cliente:** Les servirá para anticipar perfiles con alto riesgo de cancelación y aplicar políticas de retención, además de conocer la composición típica de los huéspedes (ej. familias con niños) para mejorar la experiencia durante su estancia.

A continuación, se transforman las preguntas de negocio asignadas al Grupo 3 en preguntas analíticas orientadas a la exploración de datos:

2.2. Preguntas de negocio y preguntas analíticas

Pregunta de negocio	Pregunta analítica
¿Qué segmentos de mercado o tipos de cliente concentran una mayor cantidad de reservas y cancelaciones?	¿Cuál es la frecuencia absoluta de reservas y la tasa porcentual de cancelaciones, agrupada por las variables de segmento de mercado y tipo de cliente?
¿Cómo se relacionan la anticipación de la reserva y la tarifa diaria promedio?	¿Cómo varía la distribución de la tarifa diaria promedio (ADR) a través de los diferentes rangos de días de anticipación de la reserva (lead time)?

3. Inspección y comprensión del dataset

El dataset analizado consta de **119,390 filas y 32 columnas**. Tras realizar una primera exploración en el entorno de análisis, se extrajeron las características de cada variable, sus tipos de datos y se definieron sus propiedades estadísticas.

3.1. Diccionario de variables

Tabla 1: Descripción de Variable

Variable	Descripción
hotel	Categoría del hotel (Resort Hotel o City Hotel).
is_canceled	Indica si la reserva fue cancelada (1) o no (0).
lead_time	Días de anticipación desde que se hizo la reserva hasta la fecha de llegada.
arrival_date_year	Año de la fecha de llegada.
arrival_date_month	Mes de la fecha de llegada.
arrival_date_week_number	Número de la semana del año para la fecha de llegada.
arrival_date_day_of_month	Día del mes para la fecha de llegada.
stays_in_weekend_nights	Número de noches de fin de semana (sábado o domingo) alojadas o reservadas.
stays_in_week_nights	Número de noches de lunes a viernes alojadas o reservadas.
adults	Número de adultos en la reserva.
children	Número de niños en la reserva.
babies	Número de bebés en la reserva.
meal	Tipo de comida reservada (ej. BB = Bed & Breakfast).
country	País de origen del cliente.
market_segment	Segmento de mercado que originó la reserva.
distribution_channel	Canal por donde se realizó la reserva (ej. Direct, TA/TO).

is_repeated_guest	Indica si el nombre de la reserva es de un huésped frecuente (1) o no (0).
previous_cancellations	Número de reservas canceladas previamente por el cliente antes de la reserva actual.
previous_bookings_not_canceled	Número de reservas previas no canceladas por el cliente antes de la actual.
reserved_room_type	Código del tipo de habitación que fue originalmente reservada.
assigned_room_type	Código del tipo de habitación asignada al momento de la llegada (puede variar de la reservada).
booking_changes	Número de modificaciones hechas a la reserva desde que se ingresó en el sistema.
deposit_type	Tipo de depósito requerido para la reserva.
agent	ID de la agencia de viajes que realizó la reserva.
company	ID de la compañía/empresa que realizó la reserva.
days_in_waiting_list	Número de días que la reserva permaneció en lista de espera antes de ser confirmada al cliente.
customer_type	Tipo de reserva o cliente (ej. Transient, Group).
adr	Tarifa diaria promedio (Average Daily Rate).
required_car_parking_spaces	Número de espacios de estacionamiento requeridos por el cliente.
total_of_special_requests	Número total de peticiones especiales realizadas por el cliente (ej. cama doble o piso alto).
reservation_status	Estado final de la reserva (ej. Canceled, Check-Out, No-Show).
reservation_status_date	Fecha en la que se actualizó el último estado de la reserva.

Tabla 1: Clasificación de variables

Variable	Tipo	Subtipo	Escala
hotel	Cualitativa	Nominal	Nominal
is_canceled	Cualitativa	Dicotómica	Nominal
lead_time	Cuantitativa	Discreta	Razón
arrival_date_year	Temporal	Año	Intervalo
arrival_date_month	Temporal	Mes	Ordinal
arrival_date_week_number	Temporal	Discreta	Ordinal
arrival_date_day_of_month	Temporal	Discreta	Intervalo
stays_in_weekend_nights	Cuantitativa	Discreta	Razón
stays_in_week_nights	Cuantitativa	Discreta	Razón
adults	Cuantitativa	Discreta	Razón
children	Cuantitativa	Discreta	Razón
babies	Cuantitativa	Discreta	Razón
meal	Cualitativa	Nominal	Nominal
country	Cualitativa	Nominal	Nominal
market_segment	Cualitativa	Nominal	Nominal
distribution_channel	Cualitativa	Nominal	Nominal
is_repeated_guest	Cualitativa	Dicotómica	Nominal
previous_cancellations	Cuantitativa	Discreta	Razón
previous_bookings_not_canceled	Cuantitativa	Discreta	Razón
reserved_room_type	Cualitativa	Nominal	Nominal
assigned_room_type	Cualitativa	Nominal	Nominal
booking_changes	Cuantitativa	Discreta	Razón
deposit_type	Cualitativa	Nominal	Nominal
agent	Cualitativa	Nominal	Nominal
company	Cualitativa	Nominal	Nominal

days_in_waiting_list	Cuantitativa	Discreta	Razón
customer_type	Cualitativa	Nominal	Nominal
adr	Cuantitativa	Continua	Razón
required_car_parking_spaces	Cuantitativa	Discreta	Razón
total_of_special_requests	Cuantitativa	Discreta	Razón
reservation_status	Cualitativa	Nominal	Nominal
reservation_status_date	Temporal	Fecha	Intervalo

3.2. Estructura inicial (filas, columnas, muestra, tipos de datos)

El conjunto de datos comprende un total de 119,390 filas (registros) y 32 columnas (variables).

Al importar el archivo original en el entorno de análisis R, las variables son leídas inicialmente bajo los siguientes tipos de datos automáticos:

- **Variables de texto (character):** hotel, arrival_date_month, meal, country, market_segment, distribution_channel, reserved_room_type, assigned_room_type, deposit_type, customer_type, reservation_status y reservation_status_date.
- **Variables numéricas enteras (integer):** is_canceled, lead_time, arrival_date_year, arrival_date_week_number, arrival_date_day_of_month, stays_in_weekend_nights, stays_in_week_nights, adults, babies, is_repeated_guest, previous_cancellations, previous_bookings_not_canceled, booking_changes, days_in_waiting_list, required_car_parking_spaces y total_of_special_requests.
- **Variables numéricas decimales (numeric / double):** children, agent, company y adr.

A continuación, se presenta una muestra de los tres primeros registros del dataset con las variables más representativas para observar la disposición inicial de la información:

Variable	Registro 1	Registro 2	Registro 3
hotel	Resort Hotel	Resort Hotel	Resort Hotel
is_canceled	0	0	0
lead_time	342	737	7
arrival_date_year	2015	2015	2015
arrival_date_month	July	July	July

arrival_date_day_of_month	1	1	1
stays_in_weekend_nights	0	0	0
stays_in_week_nights	0	0	1
adults	2	2	1
children	0	0	0
babies	0	0	0
meal	BB	BB	BB
country	PRT	PRT	GBR
market_segment	Direct	Direct	Direct
distribution_channel	Direct	Direct	Direct
is_repeated_guest	0	0	0
reserved_room_type	C	C	A
assigned_room_type	C	C	C
deposit_type	No Deposit	No Deposit	No Deposit
customer_type	Transient	Transient	Transient
adr	0	0	75
reservation_status	Check-Out	Check-Out	Check-Out
reservation_status_date	1/07/2015	1/07/2015	2/07/2015

Conversiones de datos necesarias para el análisis

Para preparar el dataset de manera óptima antes del análisis exploratorio en RStudio, se definen las siguientes conversiones de tipo de dato:

Conversión a Factor (factor):

- **Variables categóricas cualitativas:** hotel, meal, country, market_segment, distribution_channel, reserved_room_type, assigned_room_type, deposit_type, customer_type y reservation_status deben convertirse a tipo factor para permitir la generación de tablas de frecuencia y gráficos bivariados.
- **Variables binarias/dicotómicas:** is_canceled e is_repeated_guest son leídas como enteros (0/1), pero deben transformarse a factor con etiquetas descriptivas (ej. "No Cancelado" / "Cancelado").
- **Variables ordinales:** arrival_date_month se debe convertir a un factor ordenado respetando la secuencia cronológica de los meses del año (de enero a diciembre).

Conversión a Formato Fecha (Date):

- reservation_status_date: Se lee como texto (character). Debe convertirse a tipo Date mediante as.Date() para posibilitar filtros y análisis de series temporales.
- **Creación de fecha de llegada (arrival_date):** Se creará una nueva variable integrando arrival_date_year, arrival_date_month y arrival_date_day_of_month en formato Date para evaluar las tendencias de llegada de los huéspedes.

Reclasificación de identificadores numéricos:

- agent y company: Se importan como números decimales debido a la presencia de valores vacíos. Dado que corresponden a códigos de identificación de agencias y empresas, deben tratarse como variables de texto (character o factor).

Coerción de variables cuantitativas:

- children: Es importada como decimal debido a registros faltantes. Tras realizar la imputación de los valores nulos, se convertirá a número entero (integer).

4. Calidad, análisis exploratorio y visualizaciones

4.1. Completitud

```
setwd("C:/TB1")
df <- read.csv("hotel_bookings.csv", header = TRUE,
stringsAsFactors = FALSE)

# 1. Identificación de valores faltantes explícitos (NA)
total_filas <- nrow(df)
na_counts <- colSums(is.na(df))
na_counts <- na_counts[na_counts > 0]

faltantes_explicitos <- data.frame(
  Variable = names(na_counts),
  Valores_NA = as.numeric(na_counts),
  Porcentaje = round((as.numeric(na_counts) / total_filas) *
100, 4)
```

```

)

print("=== VALORES FALTANTES EXPLÍCITOS (NA) ===")
print(faltantes_explicitos)

# 2. Identificación de valores faltantes implícitos
("Undefined")
und_counts <- colSums(df == "Undefined", na.rm = TRUE)
und_counts <- und_counts[und_counts > 0]

faltantes_implicitos <- data.frame(
  Variable = names(und_counts),
  Valores_Undefined = as.numeric(und_counts),
  Porcentaje = round((as.numeric(und_counts) / total_filas) *
100, 4)
)

print("=== VALORES FALTANTES IMPLÍCITOS ('Undefined') ===")
print(faltantes_implicitos)

```

El análisis de completitud evaluó tanto la presencia de valores vacíos explícitos (NA) como de valores vacíos implícitos (registrados bajo la etiqueta "Undefined") en los 119,390 registros del conjunto de datos.

Resultados del diagnóstico de completitud:

- **Valores NA explícitos:**
 - company: 112,593 valores faltantes (94.31%).
 - agent: 16,340 valores faltantes (13.69%).
 - country: 488 valores faltantes (0.41%).
 - children: 4 valores faltantes (0.003%).
- **Valores implícitos (Undefined):**
 - meal: 1,169 registros marcados como "Undefined" (0.98%).
 - distribution_channel: 5 registros marcados como "Undefined".
 - market_segment: 2 registros marcados como "Undefined".

A continuación, se resumen las decisiones tomadas para el tratamiento de la completitud en la nueva versión del conjunto de datos hotel_limpio:

Problema identificado	Variable(s)	Decisión tomada	Justificación

94.31% de valores faltantes (NA)	company	Reemplazar los valores NA por 0 o el nivel categórico "Sin Compañía".	Eliminar los registros afectaría severamente el tamaño muestral. La ausencia de dato indica que la reserva fue realizada de forma particular sin convenio corporativo.
13.69% de valores faltantes (NA)	agent	Reemplazar los valores NA por 0 o el nivel categórico "Sin Agencia".	Un valor faltante indica que el cliente reservó directamente sin la intermediación de una agencia de viajes.
0.41% de valores faltantes (NA)	country	Imputar los 488 valores faltantes con la moda ("PRT" - Portugal) o la etiqueta "Desconocido".	Representa un porcentaje irrelevante del dataset (menor al 0.5%), por lo que no altera la distribución geográfica original.
0.003% de valores faltantes (NA)	children	Imputar los 4 valores faltantes con el valor 0 (moda de la variable).	Se asume que las reservas sin especificar número de niños no incluyeron menores de edad.
Valores categóricos implícitos ("Undefined")	meal	Recodificar el valor "Undefined" a "SC" (Self Catering / Sin régimen de comidas).	De acuerdo con la documentación oficial del dataset original, las reservas registradas como "Undefined" equivalen a no incluir paquete de alimentos.
Valores categóricos implícitos ("Undefined")	market_segment, distribution_channel	Imputar con la moda de la variable respectiva ("Online TA" y "TA/TO").	Al ser muy pocos casos (2 y 5 filas respectivamente), la imputación por la categoría mayoritaria no distorsiona el análisis.

```

> print("=== VALORES FALTANTES EXPLÍCITOS (NA) ===")
[1] "=== VALORES FALTANTES EXPLÍCITOS (NA) ==="
> print(faltantes_explicitos)
  Variable Valores_NA Porcentaje
1 children          4      0.0034

> print("=== VALORES FALTANTES IMPLÍCITOS ('Undefined') ===")
[1] "=== VALORES FALTANTES IMPLÍCITOS ('Undefined') ==="
> print(faltantes_implicitos)
  Variable Valores_Undefined Porcentaje
1      meal          1169      0.9791
2 market_segment           2      0.0017
3 distribution_channel       5      0.0042

```

4.2. Unicidad

```

# 1. Conteo de registros exactamente duplicados (todas las
columnas iguales)
total_registros <- nrow(df)
registros_duplicados <- sum(duplicated(df))
porcentaje_duplicados <- round((registros_duplicados /
total_registros) * 100, 2)

cat("Total de registros:", total_registros, "\n")
cat("Registros duplicados exactos:", registros_duplicados,
"\n")
cat("Porcentaje de duplicación:", porcentaje_duplicados,
"%\n")

# 2. Creación del dataset limpio sin duplicados
hotel_limpio <- unique(df)
cat("Registros únicos resultantes en hotel_limpio:",
nrow(hotel_limpio), "\n")

```

La unicidad evalúa la ausencia de registros o identificadores repetidos en la base de datos. Al analizar la totalidad del conjunto de datos original (*119,390 filas*), se detectaron las siguientes características estructurales:

1. **Ausencia de clave primaria (ID único):** El conjunto de datos no cuenta con una columna de identificador único de reserva (como **booking_id**).
2. **Registros exactamente duplicados:** Se identificaron **31,994 filas completamente idénticas** a otras dentro del dataset, lo cual representa el **26.80% del total de las observaciones**.

Análisis del problema: La presencia de un porcentaje tan elevado de filas idénticas se debe a que múltiples reservas pueden compartir exactamente los mismos atributos (mismo hotel, fechas, canal, número de huéspedes, tarifa y estado), o bien a un error en el proceso de extracción e integración de datos del sistema PMS (*Property Management System*) del hotel.

Mantener registros duplicados distorsiona los resúmenes estadísticos (agrandando artificialmente la demanda real del hotel) e infla las tasas absolutas de cancelación.

A continuación, se detalla la decisión tomada respecto a la unicidad para la construcción del dataset procesado hotel_limpio:

Problema identificado	Variable(s)	Decisión tomada	Justificación
31,994 registros exactamente duplicados (26.80%)	Todas las variables del dataset	Eliminar las 31,994 filas duplicadas en la nueva versión hotel_limpio, conservando un total de 87,396 registros únicos.	La conservación de filas completamente idénticas sesga las métricas de ocupación, tarifas medias (ADR) y porcentajes de cancelación. Su eliminación garantiza la validez estadística de los análisis bivariados y multivariados posteriores.

```
> cat("Total de registros:", total_registros, "\n")
Total de registros: 119390
> cat("Registros duplicados exactos:", registros_duplicados, "\n")
Registros duplicados exactos: 31994
> cat("Porcentaje de duplicación:", porcentaje_duplicados, "%\n")
Porcentaje de duplicación: 26.8 %
>
> # 2. Creación del dataset limpio sin duplicados
> hotel_limpio <- unique(df)
> cat("Registros únicos resultantes en hotel_limpio:", nrow(hotel_limpio), "\n")
Registros únicos resultantes en hotel_limpio: 87396
```

Conversión de variables a factor:

```
# Conversion de variables categoricas a factor
vars_factor <- c("hotel", "meal", "market_segment",
"distribution_channel", "reserved_room_type",
"assigned_room_type", "deposit_type", "customer_type",
"reservation_status") hotel_limpio[vars_factor] <-
lapply(hotel_limpio[vars_factor], as.factor)

hotel_limpio[vars_factor] <- lapply(hotel_limpio[vars_factor],
as.factor)
hotel_limpio$is_canceled <- factor(hotel_limpio$is_canceled,
levels = c(0,1), labels = c("No Cancelado", "Cancelado"))
hotel_limpio$is_repeated_guest <-
factor(hotel_limpio$is_repeated_guest, levels = c(0,1), labels
= c("No Repetido", "Repetido"))

meses_orden <-
c("January", "February", "March", "April", "May", "June", "July", "Au
gust", "September", "October", "November", "December")
hotel_limpio$arrival_date_month <- factor(hotel_limpio$arrival_da
te_month, levels = meses_orden, ordered = TRUE)

str(hotel_limpio[,
c("hotel", "is_canceled", "arrival_date_month")])
```

Las variables categóricas se transformaron a tipo factor para facilitar su análisis y representación gráfica. Asimismo, las variables binarias `is_canceled` e `is_repeated_guest` recibieron etiquetas descriptivas, mientras que `arrival_date_month` se convirtió en un factor ordenado para mantener el orden cronológico de los meses.

Corrección de la variable de fecha (arrival_date)

```
# Correccion de la variable de fecha de llegada
mes_texto <- as.character(hotel_limpio$arrival_date_month)
hotel_limpio$arrival_date <- as.Date(paste(hotel_limpio
arrival_date_year, mes_texto, hotel_limpio$arrival_date_day_of_month),
format = "%Y %B %d") cat("NA generados en arrival_date:",
sum(is.na(hotel_limpio$arrival_date)), "\n") cat("Fecha
minima:", as.character(min(hotel_limpio$arrival_date, na.rm =
TRUE)), "\n") cat("Fecha maxima:",
as.character(max(hotel_limpio$arrival_date, na.rm = TRUE)),
"\n")
```

Crea la variable `arrival_date` combinando el año, mes y día de llegada en una única fecha. Para evitar errores de conversión, primero transforma `arrival_date_month` a texto mediante `as.character()`, ya que previamente se había convertido a factor. Finalmente, verifica que no se hayan generado valores faltantes (`NA`) y muestra el rango de fechas obtenido. Esta transformación permite trabajar con una fecha completa en formato `Date`, facilitando análisis temporales y verificando que la conversión se haya realizado correctamente.

Creación de nuevas variables

```
# Correccion de la variable de fecha de llegada
mes_texto <- as.character(hotel_limpio$arrival_date_month)

hotel_limpio$total_nights <- hotel_limpio$stays_in_weekend_nights
+ hotel_limpio$stays_in_week_nights

hotel_limpio$has_children <- ifelse(hotel_limpio$children > 0 |
hotel_limpio$babies > 0, "Si", "No") hotel_limpio$has_children <-
as.factor(hotel_limpio$has_children )

summary(hotel_limpio$total_nights)
table(hotel_limpio$has_children)
```

Esta transformación genera nuevas variables de apoyo para el análisis. `total_nights` representa la duración total de la estancia, mientras que `has_children` indica si la reserva incluye niños o bebés. Posteriormente, se verifica la correcta creación de ambas variables mediante estadísticas descriptivas y tablas de frecuencia.

4.3. Consistencia

```
# Consistencia: revisar coherencia entre campos relacionados
df$fecha_llegada_tmp <- as.Date(paste(df$arrival_date_year,
df$arrival_date_month, df$arrival_date_day_of_month), format =
"%Y %B %d")
df$fecha_status_tmp <- as.Date(df$reservation_status_date, format
= "%Y-%m-%d")

incons1 <- sum(df$reservation_status == "Check-Out" &
df$is_canceled == 1)
incons2 <- sum(df$reservation_status == "Canceled" &
df$is_canceled == 0)
```



```

incons3 <- sum(df$fecha_status_tmp < df$fecha_llegada_tmp &
df$reservation_status == "Check-Out", na.rm = TRUE)

cat("Check-Out con is_canceled = 1:", incons1, "\n")
cat("Canceled con is_canceled = 0:", incons2, "\n")
cat("Check-Out registrado antes de la llegada:", incons3, "\n")

```

Se revisó la coherencia entre campos que deberían corresponderse entre sí. No se encontraron reservas con "reservation_status" = "Check-Out" marcadas simultáneamente como canceladas (is_canceled = 1), ni reservas "Canceled" marcadas como no canceladas. Tampoco se hallaron casos de Check-Out registrado antes de la fecha de llegada. El dataset es consistente en estos tres cruces de variables relacionadas.

4.4. Validez

```

# Validez: valores que violan reglas lógicas del negocio
sin_huespedes <- sum(dfadults == 0 & dfchildren == 0 & df$babies ==
0, na.rm = TRUE)
adr_neg <- sum(df$adr < 0, na.rm = TRUE)
cero_noches <- sum(dfstays_i_wk_end_nights == 0 & df
stays_in_week_nights == 0 & df$is_canceled == 0)

cat("Reservas sin ningún huésped:", sin_huespedes, "\n")
cat("Reservas con adr negativo:", adr_neg, "\n")
cat("Reservas con 0 noches y no canceladas:", cero_noches, "\n")

```

- 180 reservas no tienen ningún huésped registrado (adults = children = babies = 0), lo cual es inválido para una reserva real.
- 1 reserva presenta adr negativo, un valor sin sentido económico.
- 680 reservas no canceladas registran 0 noches de estadía (fin de semana y entre semana en cero), lo cual es inconsistente con una estancia real.

Estos casos (180 + 1 + 680 registros) se tratarán en la sección de preparación y transformación: el valor de adr negativo y los casos de 0 huéspedes/0 noches se eliminarán por no representar reservas válidas, siguiendo el mismo criterio conservador aplicado a los valores atípicos de adr en la sección 4.4.

4.5. Exactitud

No se cuenta con una fuente externa de contraste (por ejemplo, el sistema de reservas original del hotel o un registro contable paralelo) que permita verificar la exactitud de

los valores capturados. Por esta razón, este criterio de calidad no se evalúa de forma cuantitativa en el presente análisis

4.6. Análisis univariado

```
# 4.3 Analisis univariado

# Asegúrate de tener hotel_limpio creado antes

# Variables numéricas clave

summary(hotel_limpio[, c("lead_time", "adr",
"stays_in_weekend_nights", "stays_in_week_nights", "adults",
"children", "babies", "total_of_special_requests")])

# Distribución de variables categóricas

table(hotel_limpio$hotel)

table(hotel_limpio$meal)

table(hotel_limpio$market_segment)

table(hotel_limpio$distribution_channel)

table(hotel_limpio$customer_type)

table(hotel_limpio$deposit_type)

table(hotel_limpio$is_canceled)

# Gráficos univariados

dev.off()

par(mar = c(3, 3, 2, 1))

par(mfrow = c(1, 1))

hist(hotel_limpio$adr, main = "Distribución ADR", xlab = "Precio por
noche", col = "steelblue")

hist(hotel_limpio$lead_time, main = "Lead Time", xlab = "Días de
anticipación", col = "salmon")
```

```

barplot(table(hotel_limpio$hotel), main = "Tipo de hotel", col =
c("steelblue","salmon"))

barplot(table(hotel_limpio$is_canceled), main =
"Cancelaciones",names.arg = c("No cancelado","Cancelado"), col =
c("green","red"))

par(mfrow = c(1, 1))

```

El análisis univariado examina cada variable de forma individual con el objetivo de comprender su distribución, detectar comportamientos atípicos y establecer una línea base descriptiva antes de proceder con análisis de mayor complejidad. Se empleó `summary()` para las variables numéricas, ya que proporciona los estadísticos descriptivos fundamentales (mínimo, máximo, media, mediana y cuartiles). Para las variables categóricas se utilizó `table()`, que permite conocer la frecuencia absoluta de cada categoría. Los histogramas y gráficos de barras complementan el análisis numérico al hacer visible la forma de la distribución.

Resultados del análisis univariado — Variables numéricas

Variable	Mínimo	Mediana	Media	Máximo	Observación
lead_time	0	49	79.89	737	Distribución asimétrica — pocos casos con anticipación extrema
adr	-6.38	98.10	106.34	5,400	Valor negativo anómalo; máximo extremo
stays_in_weekend_nights	0	1	1.005	19	La mayoría se queda 1-2 noches de fin de semana
stays_in_week_nights	0	2	2.625	50	Estancias de hasta 50 noches son excepcionales
adults	0	2	1.876	55	Perfil típico: parejas sin menores
children	0	0	0.139	10	Mayoría sin niños; 4 NA tratados en limpieza
babies	0	0	0.011	10	Variable casi nula en la mayoría de reservas

total_of_special_requests	0	0	0.699	5	Más del 50% de huéspedes no realiza solicitudes
---------------------------	---	---	-------	---	---

Análisis del problema: La diferencia entre media y mediana en variables como **lead_time** (49 vs 79.89) y **adr** (98.10 vs 106.34) evidencia distribuciones asimétricas hacia la derecha, producidas por valores extremos que elevan artificialmente la media. El valor negativo en **adr** (-6.38) representa una anomalía que debe tratarse en la sección de valores atípicos. El máximo de 737 días en **lead_time** corresponde a reservas realizadas con casi dos años de anticipación, comportamiento atípico que podría distorsionar modelos predictivos.

Resultados del análisis univariado — Variables categóricas

Variable	Categoría dominante	Frecuencia	%	Observación
hotel	City Hotel	53,428	61.1%	Mayor representación urbana en el dataset
meal	BB (Bed & Breakfast)	67,978	77.6%	Régimen preferido ampliamente
market_segment	Online TA	51,618	59.0%	Dominio de agencias online
distribution_channel	TA/TO	69,141	79.1%	Canal mayorista predominante
customer_type	Transient	71,986	82.3%	Perfil de cliente individual mayoritario
deposit_type	No Deposit	86,251	98.6%	Casi la totalidad sin penalización por cancelación
is_canceled	No cancelado (0)	63,371	72.5%	Tasa de cancelación del 27.5%

Análisis del problema: La alta concentración en categorías únicas (como No Deposit con 98.6% o Transient con 82.3%) genera distribuciones muy desbalanceadas que pueden limitar la potencia de ciertos análisis estadísticos. Particularmente relevante es que el 98.6% de reservas se realizó sin depósito, lo cual elimina la penalización económica por cancelación y podría explicar parcialmente la tasa de cancelación del 27.5% observada.

A continuación se detallan las decisiones tomadas a partir de los hallazgos del análisis univariado:

Hallazgo identificado	Variable(s)	Decisión tomada	Justificación
Valor negativo en tarifa	adr	Tratar como outlier en sección 4.4	Un precio negativo no tiene interpretación económica válida
Distribución muy asimétrica	lead_time, adr	Aplicar análisis de outliers con regla IQR	La asimetría indica presencia de valores extremos que distorsionan la media
Categorías residuales "Undefined"	meal, market_segment, distribution_channel	Verificar que la imputación de la sección anterior fue aplicada correctamente	Se detectaron valores Undefined aún presentes en meal (492) y otras variables
Desbalance en is_canceled	is_canceled	Considerar en análisis bivariado y predictivo	Un 27.5% de cancelaciones es estadísticamente significativo y justifica análisis diferencial

```

> # 4.3 Analisis univariado
> # Asegúrate de tener hotel_limpio creado antes
> # Variables numéricas clave
>
> summary(hotel_limpio[, c("lead_time", "adr", "stays_in_weekend_nights",
+ "stays_in_week_nights", "adults", "children",
+ "babies", "total_of_special_requests")])

```

lead_time		adr	stays_in_weekend_nights		
Min.	: 0.00	Min.	: -6.38	Min.	: 0.000
1st Qu.	: 11.00	1st Qu.	: 72.00	1st Qu.	: 0.000
Median	: 49.00	Median	: 98.10	Median	: 1.000
Mean	: 79.89	Mean	: 106.34	Mean	: 1.005
3rd Qu.	: 125.00	3rd Qu.	: 134.00	3rd Qu.	: 2.000
Max.	: 737.00	Max.	: 5400.00	Max.	: 19.000

stays_in_week_nights		adults	children		
Min.	: 0.000	Min.	: 0.000	Min.	: 0.0000
1st Qu.	: 1.000	1st Qu.	: 2.000	1st Qu.	: 0.0000
Median	: 2.000	Median	: 2.000	Median	: 0.0000
Mean	: 2.625	Mean	: 1.876	Mean	: 0.1386
3rd Qu.	: 4.000	3rd Qu.	: 2.000	3rd Qu.	: 0.0000
Max.	: 50.000	Max.	: 55.000	Max.	: 10.0000

babies		total_of_special_requests	
Min.	: 0.00000	Min.	: 0.0000
1st Qu.	: 0.00000	1st Qu.	: 0.0000
Median	: 0.00000	Median	: 0.0000
Mean	: 0.01082	Mean	: 0.6986
3rd Qu.	: 0.00000	3rd Qu.	: 1.0000
Max.	: 10.00000	Max.	: 5.0000

```

> # Distribución de variables categóricas
> table(hotel_limpio$hotel)

City Hotel Resort Hotel
53428      33968
> table(hotel_limpio$meal)

BB      FB      HB      SC Undefined
67978   360   9085   9481      492
> table(hotel_limpio$market_segment)

Aviation Complementary Corporate Direct Groups
227      702      4212      11804      4942
offline TA/TO online TA Undefined
13889   51618      2
> table(hotel_limpio$distribution_channel)

Corporate Direct GDS TA/TO Undefined
5081      12988      181      69141      5
> table(hotel_limpio$customer_type)

Contract Group Transient Transient-Party
3139      544      71986      11727
> table(hotel_limpio$deposit_type)

No Deposit Non Refund Refundable
86251      1038      107
> table(hotel_limpio$is_canceled)

0      1
63371 24025
>


```

```


> # Gráficos univariados
> dev.off()
null device
1
> par(mar = c(3, 3, 2, 1))
> par(mfrow = c(1, 1))
>

```


Distribución ADR



Lead Time



Cancelaciones



4.7. Valores atípicos

```
par(mfrow = c(2, 2))
boxplot(hotel_limpio$adr, main = "Outliers ADR", col =
"steelblue")
boxplot(hotel_limpio$lead_time, main = "Outliers Lead Time", col =
"salmon")
boxplot(hotel_limpio$stays_in_week_nights, main = "Noches entre
semana", col = "lightgreen")
boxplot(hotel_limpio$adults, main = "Número de adultos", col =
"orange")

Q1 <- quantile(hotel_limpio$adr, 0.25)
Q3 <- quantile(hotel_limpio$adr, 0.75)
IQR_val <- Q3 - Q1
limite_inf <- Q1 - 1.5 * IQR_val
limite_sup <- Q3 + 1.5 * IQR_val

outliers_adr <- hotel_limpio[hotel_limpio$adr < limite_inf |
                           hotel_limpio$adr > limite_sup, ]

hotel_limpio <- hotel_limpio[hotel_limpio$adr >= 0 & hotel_limpio$adr <=
5000, ]
```

La detección de valores atípicos es una etapa crítica en la preparación del dato, ya que los outliers pueden distorsionar los estadísticos descriptivos, sesgar modelos predictivos y generar conclusiones erróneas. Se emplearon boxplots como herramienta visual inicial porque permiten identificar de forma inmediata la posición de los cuartiles, la amplitud intercuartílica y los puntos que se encuentran más allá de los bigotes. Posteriormente se aplicó la **regla IQR** (Rango Intercuartílico), el método estadístico más robusto para detectar outliers en distribuciones asimétricas, definiendo como atípico todo valor que supere $Q3 + 1.5 \times IQR$ o sea inferior a $Q1 - 1.5 \times IQR$.

Resultados por variable

ADR (precio promedio por noche)

El boxplot muestra una caja extremadamente comprimida cerca de cero con un punto aislado cerca de 5,000, lo que evidencia la presencia de un valor extremo severo. Aplicando la regla IQR se obtuvo un límite inferior de -21 y un límite superior de 227, identificándose **2,490 registros outliers**. Sin embargo, dado que valores entre 227 y 5,000 pueden corresponder a reservas legítimas de categoría superior, se optó por un criterio conservador: eliminar únicamente los registros con ADR negativo (precio sin

sentido económico) o superiores a 5,000 (claramente erróneos). Esto resultó en la eliminación de solo **2 registros**, conservando 87,394 observaciones.

Lead Time (días de anticipación)

El boxplot evidencia una distribución marcadamente asimétrica: la caja se concentra entre 0 y aproximadamente 150 días, pero los bigotes y puntos aislados se extienden hasta 737 días. Estos valores extremos corresponden a reservas realizadas con casi dos años de anticipación, comportamiento poco habitual pero que puede ser legítimo en el contexto hotelero (grupos, eventos, temporadas especiales). Por esta razón se decidió conservarlos sin eliminación.

Stays in Week Nights (noches entre semana)

La caja se comprime entre 0 y aproximadamente 5 noches, con múltiples puntos dispersos que alcanzan hasta 50 noches. Estancias tan prolongadas pueden corresponder a clientes corporativos o arrendamientos de larga duración, por lo que se mantienen en el dataset como casos válidos aunque excepcionales.

Adults (número de adultos)

La gran mayoría de reservas registra 2 adultos, pero se observan valores extremos de hasta 55 adultos, lo que resulta inverosímil para una reserva hotelera convencional y sugiere errores de captura de datos. Sin embargo, al representar una proporción mínima del total, su impacto en los estadísticos globales es marginal.


Decisiones tomadas

Hallazgo identificado	Variable(s)	Decisión tomada	Justificación
2,490 registros fuera del rango IQR	adr	Eliminar solo valores negativos y mayores a 5,000	Valores entre 227 y 5,000 pueden corresponder a reservas legítimas de lujo; solo los extremos absolutos carecen de validez económica
Valor negativo (-6.38)	adr	Eliminado	Un precio negativo no tiene interpretación válida en el contexto hotelero
Máximo de 5,400 en ADR	adr	Eliminado	Valor extremo singular con alta probabilidad de ser un error de registro

Máximos atípicos en lead_time, stays_in_week_nights, adults	lead_time, stays, adults	Conservados	Aunque excepcionales, estos valores pueden corresponder a reservas legítimas (grupos, estancias corporativas, eventos) y su eliminación podría sesgar el análisis de segmentos específicos
--	-----------------------------	-------------	--

Dataset resultante: 87,394 registros válidos tras el tratamiento de outliers, con una reducción de solo 2 registros respecto al dataset limpio previo, lo que confirma que los datos presentaban pocos errores extremos en la variable de precio.

```
> # 4.4 Valores Atípicos
> # Boxplots para detectar outliers
> par(mfrow = c(2, 2))
> boxplot(hotel_limpio$adr, main = "Outliers ADR", col = "steelblue")
> boxplot(hotel_limpio$lead_time, main = "Outliers Lead Time", col = "salmon")
> boxplot(hotel_limpio$stays_in_week_nights, main = "Noches entre semana", col = "lightgreen")
> boxplot(hotel_limpio$adults, main = "Número de adultos", col = "orange")
> par(mfrow = c(1, 1))
>
> # Regla IQR para identificar outliers en ADR
> Q1 <- quantile(hotel_limpio$adr, 0.25)
> Q3 <- quantile(hotel_limpio$adr, 0.75)
> IQR_val <- Q3 - Q1
> limite_inf <- Q1 - 1.5 * IQR_val
> limite_sup <- Q3 + 1.5 * IQR_val
>
> outliers_adr <- hotel_limpio[hotel_limpio$adr < limite_inf |
+                           hotel_limpio$adr > limite_sup, ]
> cat("Outliers en ADR:", nrow(outliers_adr), "\n")
Outliers en ADR: 2490
> cat("Límite inferior:", limite_inf, "| Límite superior:", limite_sup, "\n")
Límite inferior: -21 | Límite superior: 227
>
> # Eliminar o marcar outliers extremos (ADR negativo o > 5000)
> hotel_limpio <- hotel_limpio[hotel_limpio$adr >= 0 & hotel_limpio$adr <= 5000, ]
> cat("Registros después de tratar outliers:", nrow(hotel_limpio), "\n")
Registros después de tratar outliers: 87394
.
```



4.8. Análisis bivariado y multivariado

4.5 Análisis Bivariado y Multivariado
install.packages("corrplot")

```

library(corrplot)
corrplot(cor_matrix, method = "color", type = "upper",
         tl.col = "black", title = "Mapa de correlaciones")
# Cancelación vs tipo de hotel
tabla_cancel_hotel <- table(hotel_limpiohotel, hotel_limpiois_canceled)
prop.table(tabla_cancel_hotel, margin = 1)
barplot(prop.table(tabla_cancel_hotel, margin = 1),
       beside = TRUE, legend = TRUE,
       col = c("steelblue", "salmon"),
       main = "Cancelación por tipo de hotel",
       xlab = "Cancelado", ylab = "Proporción")

# ADR promedio por tipo de hotel
tapply(hotel_limpioadr, hotel_limpiohotel, mean)

# ADR vs cancelación
boxplot(adr ~ is_canceled, data = hotel_limpio,
       main = "ADR según cancelación",
       names = c("No cancelado", "Cancelado"),
       col = c("lightgreen", "tomato"))

# Correlación entre variables numéricas
num_vars <- hotel_limpio[, c("lead_time", "adr",
                           "stays_in_weekend_nights",
                           "stays_in_week_nights",
                           "total_of_special_requests",
                           "adults", "is_canceled")]
cor_matrix <- cor(num_vars, use = "complete.obs")
print(round(cor_matrix, 2))

# Instalar corrplot si no lo tienes: install.packages("corrplot")
library(corrplot)
corrplot(cor_matrix, method = "color", type = "upper",
         tl.col = "black", title = "Mapa de correlaciones")

# Cancelación por segmento de mercado
tabla_seg <- table(hotel_limpiomarketsegment, hotel_limpiois_canceled)
prop.table(tabla_seg, margin = 1)

```

El análisis bivariado y multivariado examina las relaciones entre dos o más variables simultáneamente, con el objetivo de identificar patrones, asociaciones y posibles

factores explicativos del comportamiento de cancelación. Se emplearon tablas de proporciones (**prop.table**) para comparar tasas de cancelación entre categorías, **tapply** para calcular medias por grupo, boxplots para visualizar la distribución del ADR según el estado de cancelación, y una matriz de correlación con mapa de calor para cuantificar las asociaciones lineales entre variables numéricas.

Resultado 1 — Cancelación por tipo de hotel

Tipo de hotel	No cancelado	Cancelado
City Hotel	69.96%	30.04%
Resort Hotel	76.52%	23.48%

Análisis: El City Hotel presenta una tasa de cancelación significativamente mayor (30.04%) que el Resort Hotel (23.48%), con una diferencia de 6.56 puntos porcentuales. Esto puede explicarse por el perfil de cliente predominante en cada tipo: los hoteles urbanos atraen mayor proporción de viajeros de negocios con reservas flexibles y cambios frecuentes de itinerario, mientras que los resorts reciben más turistas vacacionales con planes más definidos. Adicionalmente, el City Hotel registra un ADR promedio superior (110.89 vs 99.03), lo que podría indicar mayor sensibilidad al precio en las decisiones de cancelación.

Resultado 2 — ADR promedio por tipo de hotel

Tipo de hotel	ADR promedio
City Hotel	110.89
Resort Hotel	99.03

Análisis: El City Hotel cobra en promedio 11.86 más por noche que el Resort Hotel. Esta diferencia refleja la ubicación urbana y la demanda corporativa que caracteriza a este segmento. Sin embargo, a pesar de tener tarifas más altas, el City Hotel presenta mayor tasa de cancelación, lo que sugiere que el precio por sí solo no es el principal factor determinante de la cancelación.

Resultado 3 — Cancelación por segmento de mercado

Segmento	No cancelado	Cancelado
Corporate	87.89%	12.11%
Complementary	87.46%	12.54%
Direct	85.28%	14.72%
Offline TA/TO	85.15%	14.85%
Aviation	80.18%	19.82%

Groups	72.98%	27.02%
Online TA	64.65%	35.35%
Undefined	0.00%	100%

Análisis: El segmento Online TA registra la tasa de cancelación más elevada con un 35.35%, lo cual es consistente con el comportamiento típico de las reservas realizadas a través de plataformas digitales como Booking.com o Expedia, donde la facilidad de cancelación gratuita y la comparación de precios en tiempo real incentivan cancelaciones de oportunidad. En contraste, los segmentos Corporate (12.11%) y Complementary (12.54%) presentan las tasas más bajas, atribuible a que estos clientes tienen compromisos contractuales o reservas gestionadas institucionalmente. Los 2 registros "Undefined" con 100% de cancelación son residuales de la limpieza incompleta y no tienen relevancia estadística.

Resultado 4 — Matriz de correlaciones

Par de variables	Correlación	Interpretación
stays_in_weekend_nights — stays_in_week_nights	0.56	Correlación moderada positiva — estancias largas combinan ambos tipos de noches
adults — adr	0.26	A mayor número de adultos, mayor tarifa por noche
lead_time — stays_in_week_nights	0.31	Reservas con más anticipación tienden a ser de mayor duración
lead_time — is_canceled	0.18	Mayor anticipación se asocia levemente con mayor cancelación
adr — is_canceled	0.13	Las reservas más caras tienen una ligera mayor tendencia a cancelarse
total_of_special_requests — is_canceled	-0.12	Más solicitudes especiales se asocia con menor cancelación

Análisis: Ninguna variable numérica presenta una correlación fuerte con **is_canceled** (todas por debajo de 0.20), lo que indica que la cancelación es un fenómeno multifactorial que no puede explicarse de forma lineal por una sola variable numérica. La correlación negativa de **total_of_special_requests** con **is_canceled** (-0.12) es particularmente relevante: los huéspedes que realizan solicitudes especiales demuestran mayor compromiso con su reserva, resultando en menores tasas de cancelación. La correlación más alta observada (0.56) entre las noches de fin de semana y entre semana es esperable y simplemente refleja que las estancias largas abarcan ambos tipos de días.

Decisiones tomadas a partir del análisis bivariado

Hallazgo	Variables	Implicación analítica
City Hotel cancela 6.56% más que Resort Hotel	hotel, is_canceled	El tipo de hotel es una variable explicativa relevante para modelos predictivos
Online TA tiene 35.35% de cancelación	market_segment, is_canceled	El canal de venta digital es el factor categórico con mayor asociación a cancelaciones
Ninguna correlación numérica supera 0.20 con is_canceled	todas numéricas	Se requieren variables categóricas y combinaciones multivariadas para explicar la cancelación
total_of_special_requests correlaciona negativamente	requests, is_canceled	El compromiso del cliente (medido por solicitudes) es un predictor inverso de cancelación

```

> # Cancelación vs tipo de hotel
> tabla_cancel_hotel <- table(hotel_limpio$hotel, hotel_
limpio$is_canceled)
> prop.table(tabla_cancel_hotel, margin = 1)

      0      1
City Hotel  0.6996275 0.3003725
Resort Hotel 0.7651839 0.2348161
> barplot(prop.table(tabla_cancel_hotel, margin = 1),
+         beside = TRUE, legend = TRUE,
+         col = c("steelblue", "salmon"),
+         main = "Cancelación por tipo de hotel",
+         xlab = "Cancelado", ylab = "Proporción")
>
> # ADR promedio por tipo de hotel
> tapply(hotel_limpio$adr, hotel_limpio$hotel, mean)
City Hotel Resort Hotel
110.88695   99.02845
>
> # ADR vs cancelación
> boxplot(adr ~ is_canceled, data = hotel_limpio,
+         main = "ADR según cancelación",
+         names = c("No cancelado", "Cancelado"),
+         col = c("lightgreen", "tomato"))
>
> # Correlación entre variables numéricas
> cor_matrix <- cor(num_vars[, c("lead_time", "adr", "stay
s_in_weekend_nights",
+                               "total_of_special_requests",
+                               "adults", "is_canceled")])
> print(round(cor_matrix, 2))

lead_time adr
lead_time  1.00 0.03
adr         0.03 1.00
stays_in_weekend_nights 0.24 0.04
stays_in_week_nights  0.31 0.06
total_of_special_requests 0.03 0.15
adults             0.14 0.26
is_canceled        0.18 0.13

lead_time stays_in_weekend_nights
lead_time  0.24
adr         0.04
stays_in_weekend_nights 1.00
stays_in_week_nights  0.56
total_of_special_requests 0.03
adults             0.09
is_canceled        0.06

lead_time stays_in_week_nights
lead_time  0.31
adr         0.06
stays_in_weekend_nights 0.56
stays_in_week_nights  1.00
total_of_special_requests 0.04
adults             0.10
is_canceled        0.08

lead_time total_of_special_requests
lead_time  0.03
adr         0.15
stays_in_weekend_nights 0.03
stays_in_week_nights  0.04
total_of_special_requests 1.00
adults             0.11
is_canceled        -0.12

lead_time adults is_canceled
lead_time  0.14 0.18
adr         0.26 0.13
stays_in_weekend_nights 0.09 0.06
stays_in_week_nights  0.10 0.08
total_of_special_requests 0.11 -0.12
adults             1.00 0.08
is_canceled        0.08 1.00
>
> # Instalar corrplot si no lo tienes: install.packages
("corrplot")
> library(corrplot)
> corrplot(cor_matrix, method = "color", type = "upper",
+         tl.col = "black", title = "Mapa de correlacio
nes")
>
> # Cancelación por segmento de mercado
> tabla_seg <- table(hotel_limpio$market_segment, hotel_
limpio$is_canceled)
> prop.table(tabla_seg, margin = 1)

      0      1
Aviation  0.8017621 0.1982379
Complementary 0.8746439 0.1253561
Corporate  0.8789174 0.1210826
Direct     0.8528465 0.1471535
Groups     0.7298118 0.2701882
Offline TA/TO 0.8515265 0.1484735
Online TA   0.6465380 0.3534620
Undefined   0.0000000 1.0000000
> prop.table(tabla_seg, margin = 1)

```

```

> # Correlación entre variables numéricas
> num_vars <- hotel_limpio[, c("lead_time", "adr", "stay
s_in_weekend_nights",
+                               "total_of_special_requests",
+                               "adults", "is_canceled")])
> cor_matrix <- cor(num_vars, use = "complete.obs")
> print(round(cor_matrix, 2))

lead_time adr
lead_time  1.00 0.03
adr         0.03 1.00
stays_in_weekend_nights 0.24 0.04
stays_in_week_nights  0.31 0.06
total_of_special_requests 0.03 0.15
adults             0.14 0.26
is_canceled        0.18 0.13



lead_time stays_in_weekend_nights
lead_time  0.24
adr         0.04
stays_in_weekend_nights 1.00
stays_in_week_nights  0.56
total_of_special_requests 0.03
adults             0.09
is_canceled        0.06

lead_time stays_in_week_nights
lead_time  0.31
adr         0.06
stays_in_weekend_nights 0.56
stays_in_week_nights  1.00
total_of_special_requests 0.04
adults             0.10
is_canceled        0.08

lead_time total_of_special_requests
lead_time  0.03
adr         0.15
stays_in_weekend_nights 0.03
stays_in_week_nights  0.04
total_of_special_requests 1.00
adults             0.11
is_canceled        -0.12

lead_time adults is_canceled
lead_time  0.14 0.18
adr         0.26 0.13
stays_in_weekend_nights 0.09 0.06
stays_in_week_nights  0.10 0.08
total_of_special_requests 0.11 -0.12
adults             1.00 0.08
is_canceled        0.08 1.00
>
> # Instalar corrplot si no lo tienes: install.packages
("corrplot")
> library(corrplot)

```




```

# Reservas por mes
reservas_mes <- table(hotel_limpio$arrival_date_month)
barplot(reservas_mes, main = "Reservas por mes de llegada",
        col = "steelblue", las = 2, ylab = "N° reservas")

# ADR promedio por mes
adr_mes <- tapply(hotel_limpio$adr, hotel_limpio$arrival_date_month,
mean)
plot(adr_mes, type = "b", col = "darkred", pch = 19,
     main = "ADR promedio por mes",
     xlab = "Mes", ylab = "ADR promedio", xaxt = "n")
axis(1, at = 1:12, labels = substr(meses_orden, 1, 3), las = 2)

# Cancelaciones por año
table(hotel_limpio$arrival_date_year, hotel_limpio$is_canceled)

# Reservas por año y mes
library(ggplot2)
hotel_limpio$fecha_llegada <- as.Date(paste(hotel_limpio
arrival_date_year,

hotel_limpio$arrival_date_month,

hotel_limpio$arrival_date_day_of_month),
                                     format = "%Y %B %d")
ggplot(hotel_limpio, aes(x = fecha_llegada)) +
  geom_histogram(binwidth = 30, fill = "steelblue", color =
"white") +
  labs(title = "Evolución de reservas en el tiempo",
       x = "Fecha de llegada", y = "N° reservas") +
  theme_minimal()

```

El código permite realizar un análisis temporal de las reservas, considerando el mes y año de llegada, el ADR promedio y la evolución de las reservas a través del tiempo. Primero se carga la librería **lubridate**, utilizada para trabajar con fechas, y **ggplot2**, utilizada para la representación gráfica. Luego, se establece el orden cronológico de los meses mediante un factor para evitar que sean organizados alfabéticamente. A continuación, se utiliza **table()** para obtener la cantidad de reservas correspondientes a cada mes y **barplot()** para representar gráficamente su distribución, permitiendo identificar los periodos con mayor y menor cantidad de

reservas. Posteriormente, mediante `tapply()` se calcula el ADR promedio para cada mes y se representa mediante un gráfico de líneas, lo que permite observar las variaciones de las tarifas promedio durante el año. También se genera una tabla que relaciona el año de llegada con la variable `is_canceled`, donde `0` representa reservas no canceladas y `1` reservas canceladas, permitiendo comparar el comportamiento de las cancelaciones entre los años registrados. Finalmente, se construye una variable de fecha completa utilizando el año, mes y día de llegada para representar la evolución de las reservas mediante un histograma. En la ejecución inicial se obtuvo una advertencia indicando que **87,394 registros fueron eliminados por contener valores no finitos**, lo que evidencia que la conversión de la fecha no se realizó correctamente para una gran cantidad de registros. Por ello, este último gráfico debe interpretarse con precaución y la conversión de `fecha_llegada` debe corregirse antes de utilizarlo como evidencia definitiva. En conjunto, el análisis permite identificar patrones temporales en el volumen de reservas, variaciones del ADR y comportamiento de las cancelaciones según el periodo.


```
> # 2. Ahora sí lo cargamos junto a ggplot2
> library(lubridate)
> library(ggplot2)
>
> # Convertir mes a factor ordenado
> meses_orden <- c("January", "February", "March", "April", "May", "June",
+ "July", "August", "September", "October", "November", "December")
> hotel_limpio$arrival_date_month <- factor(hotel_limpio$arrival_date_month,
+ levels = meses_orden)
>
> # Reservas por mes
> reservas_mes <- table(hotel_limpio$arrival_date_month)
> barplot(reservas_mes, main = "Reservas por mes de llegada",
+ col = "steelblue", las = 2, ylab = "N° reservas")
>
> # ADR promedio por mes
> adr_mes <- tapply(hotel_limpio$adr, hotel_limpio$arrival_date_month, mean)
> plot(adr_mes, type = "b", col = "darkred", pch = 19,
+ main = "ADR promedio por mes",
+ xlab = "Mes", ylab = "ADR promedio", xaxt = "n")
> axis(1, at = 1:12, labels = substr(meses_orden, 1, 3), las = 2)
>
> # Cancelaciones por año
> table(hotel_limpio$arrival_date_year, hotel_limpio$is_canceled)


```

	0	1
2015	10609	2704
2016	31183	11207
2017	21578	10113

```
>
> # Reservas por año y mes
> library(ggplot2)
> hotel_limpio$fecha_llegada <- as.Date(paste(hotel_limpio$arrival_date_year,
+ hotel_limpio$arrival_date_month,
+ hotel_limpio$arrival_date_day_of_mon
+ ))

```





5. Respuesta a las preguntas analíticas


A partir de la depuración del conjunto de datos y el análisis estadístico bivariado, se procedió a dar respuesta a las dos preguntas analíticas planteadas por el equipo:

1. ¿Cuál es la frecuencia absoluta de reservas y la tasa porcentual de cancelaciones, agrupada por las variables de segmento de mercado y tipo de cliente?

El análisis exploratorio revela patrones de comportamiento muy marcados dependiendo del origen de la reserva y el perfil del huésped:

- **Por tipo de cliente:** El cliente de categoría *Transient* (transitorio o individual) concentra la gran mayoría de la demanda absoluta con **71,985 reservas**, y a su vez representa el mayor riesgo, con una **tasa de cancelación del 30.10%**. Le siguen de lejos los clientes *Transient-Party* con 11,726 reservas (15.24% de cancelación) y *Contract* con 3,139 reservas (16.31%). Los clientes de tipo *Group* son los menos frecuentes (544 reservas) pero los más seguros, con una cancelación de apenas 9.93%.
- **Por segmento de mercado:** Las agencias de viajes en línea (*Online TA*) dominan abrumadoramente la captación con **51,618 reservas**, pero sufren la **tasa de cancelación más alta del análisis con un 35.35%**. En contraste, los canales más tradicionales como *Offline TA/TO* (13,888 reservas) y el canal directo *Direct* (11,804 reservas) presentan tasas de cancelación significativamente menores y muy similares entre sí, con 14.85% y 14.72% respectivamente.

Reservas y Cancelaciones por Segmento de Mercado




2. ¿Cómo varía la distribución de la tarifa diaria promedio (ADR) a través de los diferentes rangos de días de anticipación de la reserva (lead time)?

El cálculo de correlación de Pearson arrojó un valor muy cercano a cero ($r = 0.025$), lo que demuestra que no existe una relación lineal simple (proporcional) entre los días de anticipación y el precio. Sin embargo, al agrupar la variable continua *lead time* en rangos de días, se observa una clara distribución en forma de curva (comportamiento no lineal) impulsada por el comportamiento de las tarifas estacionales:

- **0 a 30 días:** Las reservas de corto plazo o "último minuto" presentan una tarifa promedio de **100.17**.
- **31 a 90 días:** La tarifa promedio comienza a ascender a **111.07**.
- **91 a 180 días:** En esta ventana de 3 a 6 meses de anticipación se alcanza el **pico máximo de precio**, pagando el ADR más alto con **114.03**.
- **181 a 365 días:** Para reservas a mediano/largo plazo, la tarifa vuelve a descender a **103.73**.
- **Más de 365 días (1 año a más):** Quienes reservan con anticipación extrema logran conseguir el precio más económico, con un ADR promedio de **80.69**.

Esto concluye que el hotel no cobra más caro a quienes reservan a último minuto, sino a quienes planifican en la ventana de los 3 a 6 meses previos a su llegada.

ADR según Rango de Anticipación



Con el objetivo de garantizar la validez estadística del análisis, se creó una nueva versión del conjunto de datos denominada `hotel_limpio`, en la cual no se alteró el archivo original, sino que se registraron todas las decisiones de preparación, imputación y eliminación de errores estructurales.

A continuación, se presenta la tabla resumen con las decisiones tomadas durante el preprocesamiento:

Problema Identificado	Variables	Decisión Tomada	Justificación
Registros duplicados	Todas	Se eliminaron 31,994 registros idénticos (26.80% del dataset).	Conservarlos infla artificialmente la demanda real del hotel y distorsiona el cálculo de ingresos y tasas de cancelación.
Valores atípicos extremos e	adr	Se eliminaron las tarifas menores a	Una tarifa negativa es un error de

inválidos		0 (valores negativos) y un registro extremo superior a 5,000.	digitación o sistema. El valor >5,000 distorsiona severamente el promedio y el análisis bivariado.
Fechas fragmentadas	arrival_date_year, arrival_date_month, arrival_date_day_of_month	Se creó una nueva variable fecha_llegada unificando los tres campos en formato temporal Date.	Facilita la elaboración de la visualización temporal obligatoria y el análisis de series de tiempo para evaluar la demanda.
Tipos de datos incorrectos	is_canceled, arrival_date_month	Se convirtieron de valores enteros y caracteres a variables de tipo factor y factor ordenado.	Permite el correcto funcionamiento de las funciones de agrupación, la generación de resúmenes estadísticos univariados y el orden cronológico en los gráficos.

6. Comunicación de hallazgos

6.1. Síntesis de hallazgos

Hallazgo	Evidencia que lo respalda	Interpretación
El segmento Online TA concentra la mayor cantidad de reservas y presenta la tasa de cancelación más alta (35.35%).	Tabla de proporciones por segmento de mercado (sección 4.5, <code>prop.table(tabla_seg)</code>).	Las agencias de viajes online representan un canal importante de captación, pero también presentan una mayor proporción de cancelaciones, por lo que requieren estrategias de seguimiento y retención.
El tipo de depósito Non Refund presenta la mayor tasa de cancelación (94.70%), superando a No Deposit (26.69%).	Tabla de proporciones depósito vs. cancelación (sección 4.7).	Es un resultado que debe revisarse con las frecuencias de cada categoría, ya que una tasa elevada de cancelación en las reservas no reembolsables es un comportamiento que requiere

		mayor análisis.
Los huéspedes repetidos cancelan mucho menos.	7.64% frente a 28.30% en huéspedes no repetidos.	La fidelización se asocia con un mayor compromiso de reserva.

7. Conclusiones y recomendaciones

7.1. Conclusiones

- Los clientes transitorios (*Transient*) y las agencias de viajes en línea (*Online TA*) constituyen la principal fuente de demanda del hotel, pero representan simultáneamente el mayor desafío operativo debido a que concentran un tercio de las cancelaciones totales.
- Existe una brecha significativa de fidelidad operativa: mientras un cliente corporativo o de grupo cancela 1 de cada 10 reservas, el cliente individual de internet cancela casi 4 de cada 10.
- La anticipación de la compra (*lead time*) no tiene una relación directamente proporcional con la tarifa (*ADR*). Los precios más altos no los pagan quienes reservan a último minuto, sino quienes lo hacen en la ventana estratégica de 90 a 180 días previos a su llegada.
- Permitir reservas con más de un año de anticipación (>365 días) resulta en las tarifas diarias promedio más bajas, lo que podría estar generando un costo de oportunidad para el hotel en épocas de alta demanda.

7.2. Recomendaciones

- Implementar políticas de depósitos o tarifas no reembolsables específicamente dirigidas al segmento Online TA y clientes Transient, ofreciendo un ligero descuento a cambio de asegurar el pago por adelantado para reducir la alta tasa de cancelación (35%).
- Optimizar el algoritmo de precios (Revenue Management): Restringir la disponibilidad de tarifas excesivamente económicas para reservas con más de un año de anticipación y concentrar los esfuerzos de marketing para captar venta directa en la ventana de 90 a 180 días, que ha demostrado ser la más rentable ($ADR > 114$).

7.3. Limitación del análisis

- El conjunto de datos carece de variables que expliquen los motivos específicos de las cancelaciones (por ejemplo, factores climáticos, problemas de salud, cancelación de vuelos o alertas económicas). Esto impide crear un modelo predictivo exacto que determine por qué un cliente Transient decide finalmente no viajar.

8. Bibliografía

Antonio, N., de Almeida, A., & Nunes, L. (2019). *Hotel booking demand datasets* [Conjunto de datos]. Data in Brief. <https://www.sciencedirect.com/science/article/pii/S2352340918315191>

R Core Team. (2026). *R: A language and environment for statistical computing* [Software]. R Foundation for Statistical Computing. <https://www.R-project.org/>

9. Anexo: Uso responsable de IA

Herramienta utilizada: Gemini.

Propósito de uso: Apoyo en la sintaxis del código en R.

Prompt representativo: "Error en `unique.default(df)`: `unique()` puede ser aplicada solamente a vectores. ¿Cómo soluciono este error al limpiar mi dataset en R base?"

Forma de verificación: El equipo ejecutó el código en el entorno de RStudio para validar su correcto funcionamiento sin errores. Se revisaron los resultados en consola y los gráficos generados para confirmar que la sintaxis aplicada respondiera correctamente a las preguntas analíticas del grupo.